Informe de revisión por pares (segunda lectura)

Manuscrito: *Two barriers to equitable access: WCAG conformance and pre-consent tracking on Ecuadorian and top-ranked university websites*

Revista: *Behaviour & Information Technology* (Taylor & Francis)

Lectura independiente de la versión anonimizada revisada (47 páginas) — 11 de noviembre de 2026

Este informe evalúa la versión revisada del manuscrito como si llegara por primera vez a la revista. Leí el texto completo, recalculé las cifras nuevas a partir del depósito público de datos (versión 1.1.0) y verifiqué las referencias añadidas. Las citas del manuscrito se reproducen en inglés, tal como aparecen en el original.

1. Veredicto

Recomendación: **revisión mayor, acotada a un solo problema de fondo**. La versión revisada resuelve casi todo lo que hacía vulnerable a la anterior: el enfoque ahora corresponde a la revista, la atribución al proveedor se apoya en registros de red y las afirmaciones se ajustan a lo medido. Queda un problema que sí afecta a las conclusiones principales: los indicadores documentales, que sostienen las diferencias más grandes del estudio, se compilaron con ayuda de inteligencia artificial y no tienen ninguna medida de fiabilidad. Si los autores lo resuelven con la recodificación independiente que ellos mismos proponen, el artículo quedaría en condiciones de aceptarse con cambios menores.

Table 1: Respuestas al formulario del revisor.

Pregunta	**Respuesta**
¿El tema está dentro del alcance de la revista?	Sí, tras la reorientación
¿El trabajo es original?	Sí
¿Los métodos son adecuados y están bien descritos?	Sí, salvo la fiabilidad documental
¿Las conclusiones se siguen de los resultados?	Sí, con dos matices (apartado 4)
¿El análisis estadístico es correcto?	Sí; cifras reproducidas
¿Las referencias son adecuadas?	Sí
¿La presentación y la extensión son adecuadas?	Presentación sí; extensión excesiva
Recomendación	Revisión mayor (acotada)

2. Lo que la versión revisada hace bien

- **Encaje con la revista.** El resumen ya no está estructurado y tiene 197 palabras, hay seis palabras clave, y el nuevo apartado 5.3 (“*What users can see and do*”) conecta los hallazgos con la conducta del usuario. Las siete referencias de la revista añadidas existen, sus datos coinciden con Crossref y lo que el texto les atribuye coincide con sus resúmenes.

- **Atribución al proveedor demostrada en la capa correcta.** La campaña del 16 de agosto registra las peticiones de red y permite distinguir si la cookie la retiene el proveedor o una capa anterior. El resultado es matizado y honesto: Microsoft decide en 13 de 14 sitios, mientras que en TapAd la petición ni siquiera sale desde Europa. Reproduje la Tabla 7 completa con `vendor_layer.py` y coincide celda por celda.
- **Control de red bien diseñado.** Fráncfort y Miami usaron el mismo sistema autónomo (AS46475) en las seis pasadas, y las 105 comprobaciones de ubicación coinciden con el punto declarado.
- **Menos dependencia de la IA en los resultados.** Los veredictos de la validación manual salen ahora de la segunda codificación, enteramente humana, y la lectura asistida queda como análisis de sensibilidad (59 % frente a 61 %). Comprobé en el depósito que la segunda codificación da 12 sitios fallidos en 1.1.1 y que la Tabla 4 tiene 23 casillas en negrita, como dice el texto.
- **Transparencia.** La declaración de uso de IA es detallada, el texto ya no afirma doble codificación documental y el depósito ya no contiene direcciones de contacto.
- **Honestidad estadística.** El texto informa que la diferencia entre Ecuador y Alemania del 16 de agosto no sobrevive al ajuste de Holm: "*in this family of ten comparisons that contrast does not survive Holm adjustment*".

3. Problemas mayores

3.1. Los indicadores documentales no tienen ninguna medida de fiabilidad

Las diferencias más grandes y más citadas del artículo son documentales: contacto de privacidad (47,6 puntos), declaración de accesibilidad (63,5) y aviso de privacidad (31,7). El resumen abre con una de ellas. Sin embargo, el apartado 3.4 indica que la matriz se compiló con ayuda de IA y que "*The three authors and one external collaborator then took part in coding and reviewing the matrix, but their individual codings were not retained*". La única comprobación manual cubre 24 celdas de seis instituciones elegidas a propósito, y encontró dos errores. El propio texto reconoce que esa cifra "*is neither an upper nor a lower bound on the error rate of the full matrix*".

Esto deja la conclusión principal del artículo sin respaldo de fiabilidad. Que la primera versión de los datos la produjera un sistema de IA agrava el problema: un lector no puede saber cuántas celdas se revisaron a fondo y cuántas se aceptaron tal como las propuso el sistema. La medida habitual es el acuerdo entre dos personas que codifican lo mismo sin ver el trabajo de la otra, corregido por el acuerdo esperado por azar (coeficiente kappa de Cohen).

Pido a los autores:

1. Realizar la doble codificación independiente que ellos mismos proponen como trabajo futuro: dos personas, sin IA, sobre una muestra aleatoria de al menos 30 instituciones, con kappa por indicador. Para la muestra basta una tarde de trabajo por persona, y convierte la principal debilidad del estudio en un dato publicable.
2. Informar también el acuerdo de cada codificador humano con la matriz publicada. Eso estima cuántas celdas de la matriz asistida habría corregido una lectura humana independiente.
3. Si no es posible antes del envío, mencionarlo en el resumen. Hoy el resumen presenta las cifras documentales sin ninguna advertencia, mientras que la limitación solo aparece en los apartados 3.4 y 5.6.

3.2. Extensión

El cuerpo tiene unas 17 800 palabras, a las que se suman unas 2 500 de apéndices, 11 tablas y 6 figuras. La revisión añadió contenido sin recortar, y algunos apartados son muy largos: el 4.7 tiene unas 2 200

palabras y el de amenazas a la validez unas 1 400. Conviene confirmar el límite en las instrucciones oficiales de la revista. En cualquier caso hay recortes que no quitan nada sustantivo:

- Pasar a material suplementario los apéndices C y D (matrices por institución), que ya están en el depósito.
- Reducir el apartado 4.7 a sus tres hallazgos (diferencia por país, capa de decisión y réplica) y dejar en el suplemento la explicación de las tres cifras de Ecuador y el detalle de las cinco exclusiones.
- Condensar el apartado 2.3 ("*The gap addressed here*"), que repite lo que ya dice la introducción.

4. Problemas menores

1. **Señales de consentimiento en los 13 sitios de Microsoft.** La regla de atribución supone que, si la petición sale y no hay cookie, decidió el proveedor. Una alternativa es que el propio sitio pase al proveedor una señal de consentimiento por región, y que el código del proveedor solo la obedezca. El instrumento registra esas señales (campo `consentimiento_por_defecto`). Lo comprobé en el depósito: en 11 de los 13 sitios no hay plataforma de consentimiento ni señal de consentimiento declarada para Microsoft (UET o Clarity) o Google, y en los otros dos (CMU con OneTrust y UIDE con CookieYes) sí hay plataforma de consentimiento. Es un dato que refuerza la conclusión y debe estar en el texto. Para CMU y UIDE corresponde decir que no puede descartarse una señal transmitida por la plataforma.
2. **Igualdad de las señales del navegador.** Conviene declarar que la zona horaria y el idioma del navegador fueron los mismos en los cinco puntos (el instrumento no los fija, así que toma los del equipo). Con eso queda claro que lo único que cambió fue la dirección IP, y que el proveedor decidió por la ubicación de red.
3. **El resumen no menciona la réplica.** El resumen da "*67.8% of visits from Ecuador and 60.3% of visits from Germany*", del 15 de agosto. Al día siguiente la diferencia tuvo la misma dirección (seis sitios, todos en el mismo sentido), pero no sobrevivió al ajuste por comparaciones múltiples. Una frase en el resumen lo dejaría claro.
4. **Intervalos sin ajustar en la Figura 1.** La leyenda dice "*Filled squares mark intervals that exclude zero*". Con ese criterio aparecen como diferencias claras los derechos enumerados, la ausencia total de fallos automáticos y el certificado TLS, cuyos valores ajustados por Holm son 0,235, 0,193 y 0,288. La leyenda debe advertir que los intervalos no están ajustados por comparaciones múltiples.
5. **Cifra de comprobaciones de ubicación.** En amenazas a la validez se lee "*geolocation was verified 84 times*", que es la cifra del 15 de agosto. Con la campaña del 16 se suman 105 comprobaciones más.
6. **Selección de la submuestra manual.** El texto reconoce que "*The subsample of fifteen sites was selected purposively and the selection criterion was not recorded*". Es una limitación bien declarada, pero si existe algún registro del criterio, conviene añadirlo.
7. **Agradecimientos.** La versión completa no tiene apartado de agradecimientos, aunque el apartado 3.4 menciona a una persona colaboradora externa que participó en la codificación. Hay que reconocerla, con su consentimiento.
8. **Política de la revista sobre IA.** El uso de IA declarado es amplio: compiló la primera versión de la matriz documental y redactó y ejecutó un script de análisis. Los autores deben confirmar que la declaración cumple la política vigente de Taylor & Francis sobre herramientas de IA generativa.

5. Comentarios confidenciales para el editor

La revisión es seria y responde a las críticas con datos, no con retórica. El hallazgo sobre la capa de decisión del proveedor es original y está bien demostrado. Mi reserva principal es la fiabilidad de los indicadores documentales: hoy descansan en una matriz compilada con IA y revisada sin registro, y son la base de las conclusiones más citables. No veo indicios de manipulación de datos; al contrario, los autores declaran sus limitaciones con un detalle poco común. Si completan la recodificación independiente y recortan la extensión, recomendaría aceptar.